INSTITUTO ELDORADO

RESIDÊNCIA EM INTELIGÊNCIA ARTIFICIAL (RES-IA)



Lucas — Engenharia de Dados & Dev
Jhessica — Ciência de Dados
Clara — Arquitetura de Soluções
Nasser — Arquitetura de Soluções
Ingrid Soares — Ops (DevOps & MLOps)

Semana 3 — Relatório Experimental: LLM x RAG

Sócio Digital: Copiloto de Gestão Fiscal para Pequenos Negócios

Challenge 2: Qualidade de Vida e Tomada de Decisão com IA — Grupo 08

Estudo Comparativo de 4 Topologias, Métricas de Avaliação e Quality Gate MLOps

Brasília - DF
Novembro / 2026

SUMÁRIO

Resumo Executivo e Briefing Oficial da Semana 3 2
1. Contexto, Equipe e Proposta Experimental 3
1.1. Motivação e Desafios de Confiabilidade Tributária 3
1.2. Matriz de Atuação Técnica da Equipe (Grupo 08) 3
1.3. Protocolo Experimental e Dataset Ground Truth 3
2. Especificação Rigorosa das Métricas de Avaliação 3
2.1. Dimensão 1: Métricas de Recuperação (Retriever) 3
2.2. Dimensão 2: Métricas de Geração e Fidelidade Factual 3
2.3. Dimensão 3: Métricas de Engenharia e Operação MLOps 3
3. Definição Aprofundada dos Quatro Testes Experimentais 4
3.1. Teste 1: LLM Pura (Zero-Shot / Direct Generation sem RAG) 4
3.2. Teste 2: RAG Sem LLM (Recuperação Pura + Template Fixo) 4
3.3. Teste 3: Naive RAG (Busca Vetorial Densa Top-K + LLM) 4
3.4. Teste 4: RAG Híbrido Avançado com Reranker e Guardrails 4
4. Resultados do Benchmark Comparativo Quantitativo 5
4.1. Tabela Consolidada de Métricas nos Quatro Testes 5
4.2. Análise Crítica dos Trade-offs e Variações Observadas 5
4.3. Escolha Arquitetural Ótima para o Sócio Digital 5
5. Governança MLOps, Links do Repositório e Conclusão 6
5.1. Esteira CI/CD com Quality Gate e MLflow Tracking 6
5.2. Links Oficiais para o Repositório e Artefatos 6
5.3. Cronograma da Semana 4 e Fechamento Oficial 6

Briefing Oficial da Proposta — Semana 3 (RES-IA Challenge 2)

Contexto e Demanda da Coordenação RES-IA:
"Na última semana vocês desenvolveram o RAG e, como sabemos, ele precisa de uma LLM. Uma semana é pouco para tanta coisa, então as métricas e as escolhas de modelo provavelmente ainda podem ser melhoradas.
• ***Proposta:*** *comparar o uso de LLM x RAG, melhorar as métricas e testar diferentes formas de usar o RAG. Exemplo: com e sem LLM, o que muda e por que muda.*
• ***Entregável:*** *um relatório detalhando os testes, a metodologia utilizada e os links para o projeto.*
• ***Critério de pronto:*** *fazer 4 testes diferentes e escolher o melhor para o produto de vocês.*
• ***Deadline:*** *Sexta-feira (13/11/2026)."*

Posicionamento do Grupo 08: O presente relatório atende integralmente às exigências especificadas. Definimos e executamos 4 testes empíricos rigorosamente controlados sobre a base de conhecimento normativo do **Sócio Digital** (assistente contábil e tributário para MEIs e MEs), mensurando recuperação de fontes, chegada do artigo esperado ao contexto, recusas, estabilidade entre repetições e latência, com rastreabilidade formal via MLflow e esteira CI/CD.

Residência Tecnológica em Inteligência Artificial (RES-IA) — Challenge 2

1. Contexto, Equipe & Metodologia de Avaliação

Estruturação dos Cenários Fiscais e Governança Multidimensional de Métricas

1.1. Motivação e Desafios de Confiabilidade Tributária

Na Semana 2, o Grupo 08 estruturou o piloto do **Sócio Digital**. No domínio fiscal brasileiro, a margem para erro é nula: informações incorretas sobre prazos de DAS, reenquadramento de MEI ou Fator R do Simples Nacional acarretam multas e penalidades no Portal e-CAC. Assim, o objetivo da Semana 3 é testar hipóteses sobre o papel da LLM e do RAG, definindo uma arquitetura factual, ética e de baixa latência.

1.2. Atuação Técnica da Equipe na Semana 3

Integrante	Frente no RES-IA	Entregas Concretas na Semana 3 (LLM x RAG)
Lucas	Engenharia de Dados & Dev	Refatoração do pipeline de ingestão tributária, chunking e integração com APIs FastAPI.
Jhessica	Ciência de Dados	Projeto do conjunto de avaliação (81 perguntas), parametrização dos 4 testes e avaliação das respostas.
Clara	Arquitetura de Soluções	Desenho dos fluxos com/sem LLM, contratos de serviço e desacoplamento de regras fiscais.
Nasser	Arquitetura de Soluções	Mapeamento de riscos de alucinação jurídica, requisitos de abstenção ética (CRC) e latência.
Ingrid Soares	Ops (DevOps & MLOps)	Quality Gate no CI/CD (GitHub Actions), rastreamento MLflow e automação de relatórios.

2. Especificação Detalhada das Métricas de Avaliação

Para transcender avaliações qualitativas e subjetivas, formalizamos uma suíte com 81 perguntas (teste_ampliado_2026-11-12.jsonl), repetidas 3 vezes, e especificamos métricas em 3 dimensões essenciais para o produto:

Dimensão	Métrica & Sigla	Definição Operacional / Algorítmica	Meta / Quality Gate
Recuperação	**Recall@8 (leniente)**	Proporção de perguntas cuja norma esperada (ou equivalente aceita) está entre as 8 fontes recuperadas da base.	**≥ 80,0% (Top-8)**
Recuperação	**MRR@8 (leniente)**	Inverso da posição da primeira fonte correta entre as 8 recuperadas; mede se a norma certa aparece no topo.	**≥ 0,65 (Posição)**
Recuperação	**artigo_esperado**	Proporção dos pares (norma, artigo) esperados que aparecem entre as 8 fontes recuperadas; mede se o artigo certo chegou ao contexto.	**≥ 80,0% (Artigo certo)**
Geração	**citacao_suportada**	Proporção de citações da resposta que aparecem de fato no contexto enviado ao modelo; avalia citação inventada.	**≥ 95,0% (Fidelidade)**
Governança	**Recusa fora do acervo**	Taxa de recusa quando a pergunta não tem base no acervo, em vez de inventar uma resposta (9 perguntas x 3 repetições).	**100,0% (Mandatório)**
Conformidade	**Clarify (acerto)**	Taxa de pedidos de esclarecimento quando faltam dados (faturamento, regime, atividade), em vez de supor (10 perguntas x 3 repetições).	**≥ 80,0% (Padronizado)**
Engenharia	**Latência (mediana / p95)**	Tempo total de resposta (processamento + busca vetorial + reranker + inferência LLM) em GPU de 12 GB, sob a carga do teste.	**≤ 5 s / ≤ 15 s (RNF08)**

Residência Tecnológica em Inteligência Artificial (RES-IA) — Challenge 2

3. Definição Aprofundada dos Quatro Testes

Análise Comparativa: O Que Muda, Por Que Muda e Topologias de RAG Avaliadas

Para atender ao desafio central de comparar sistematicamente **LLM x RAG** e responder *o que muda e por que muda*, estruturamos quatro topologias experimentais controladas:

TESTE 1: LLM Pura (Zero-Shot / Direct Generation sem RAG)

Arquitetura: A dúvida contábil do usuário é enviada diretamente à LLM local (qwen3:8b via Ollama) com um prompt de sistema simples, sem fornecer base documental externa ou contexto recuperado.
O que muda: As respostas saem coesas, mas sem base legal: nas 81 perguntas (3 repetições) sem recuperação o artigo esperado nunca chega ao contexto (artigo_esperado 0,000), o modelo não recusou nenhuma das 27 tentativas fora do acervo e não pediu esclarecimento em nenhuma das 30 tentativas que o exigem. O ROUGE-L cai para 0,118 (contra 0,217 do sistema completo) e a concordância entre repetições é de 0,695.
Por que muda: Modelos de linguagem pura dependem estritamente de memória paramétrica. Sem grounding em documentos fiscais oficiais no momento da inferência, o modelo gera conteúdo plausível, porém sem fonte verificável nem o artigo correto.

TESTE 2: RAG Sem LLM (Recuperação Pura / Semantic Search + Template Fixo)

Arquitetura: A dúvida do usuário é convertida em embedding vetorial (qwen3-embedding:0.6b) e submetida ao banco Qdrant. Os 3 trechos mais próximos pela busca densa são injetados diretamente em um modelo de texto fixo, sem passar por LLM geradora.
O que muda: Latência mínima (mediana de 0,19 s) e nenhuma geração, com 91,9% das citações suportadas pelo contexto. Porém a qualidade despenca: o artigo esperado chega ao contexto em apenas 30,5% dos casos, o ROUGE-L é 0,066 e o microempreendedor leigo recebe trechos brutos de leis fiscais complexas ("juridiquês"), sem síntese em linguagem acessível, sem recusar perguntas fora do acervo (0/27) e sem pedir esclarecimento (0/30).
Por que muda: Eliminar a LLM remove o custo e a variação da geração, mas elimina também a capacidade de sintetizar, traduzir a norma para linguagem acessível e montar um fluxo acionável passo a passo. Com apenas 3 trechos da busca densa, a norma certa também fica de fora com frequência.

TESTE 3: Naive RAG (Busca Vetorial Densa Top-K + LLM Geradora Padrão)

Arquitetura: Pipeline clássico em que uma busca densa por similaridade de cosseno no Qdrant recupera os 8 trechos mais próximos e os envia à LLM (qwen3:8b) com o prompt de sistema padrão, sem busca esparsa, sem reranker e sem busca direta pelas normas e artigos citados na pergunta.
O que muda: Grande evolução em relação à LLM pura: o artigo esperado chega ao contexto em 54,3% dos casos, o ROUGE-L sobe para 0,246 e 95,3% das citações são suportadas pelo contexto. Porém revela duas fraquezas: (1) consultas com termos técnicos precisos (número da lei, artigo, código) falham na recuperação puramente semântica, deixando o artigo esperado 25 pontos percentuais abaixo do RAG híbrido com reranker; (2) a concordância entre repetições fica em 0,889 e nenhuma pergunta fora do acervo é recusada (0/27).
Por que muda: A busca densa capta o sentido semântico geral, mas perde correspondências exatas de palavras-chave fiscais. Além disso, a ausência de reranking entrega contexto com ruído para a LLM.

TESTE 4: RAG Híbrido Avançado com Reranker e Guardrails Éticos (TOPOLOGIA ELEITA)

Arquitetura: Pipeline que combina: (1) *Busca Híbrida:* recuperação densa vetorial (Qdrant) + busca esparsa lexical (vetor esparso com IDF) para termos técnicos (artigos, leis, siglas); (2) *Reranking:* reordenação dos 30 candidatos pelo cross-encoder bge-reranker-v2-m3, com os 8 melhores seguindo para o contexto; (3) *Busca direta:* trechos das normas e artigos citados na pergunta; (4) *Guardrails:* regra de esclarecimento do modelo, que pede os dados que faltam antes de buscar, e detecção, no texto da resposta, de recusa e de pedido de dados, que viram status explícitos; (5) *Inferência controlada:* qwen3:8b com temperatura 0 e recusa por contexto insuficiente.
O que muda: É a topologia mais próxima das metas e a única que pede esclarecimento: clarify 30/30 (atinge a meta), citacao_suportada 0,992 e concordância entre repetições 0,934 (ambas atingem), artigo_esperado 0,790 (meta 0,80), Recall@8 leniente 0,639, MRR leniente 0,481, ROUGE-L 0,217 e latência mediana de 2,22 s (p95 de até 12,62 s). Atinge a recusa fora do acervo (27/27, sem a pergunta do FGTS; ver 4.2). Ainda não atinge: recusas indevidas (15/183, 8,2%) e falsos positivos (15/183, 8,2%).
Por que muda: A busca híbrida resolve o gargalo de termos exatos; o reranker filtra ruídos antes da LLM; os guardrails trocam respostas que apenas recusam ou pedem dados por status explícitos (contexto insuficiente e pedido de esclarecimento), o que também expõe recusas que antes constavam como resposta; e o prompt de sistema restringe a resposta ao que a base sustenta.

Residência Tecnológica em Inteligência Artificial (RES-IA) — Challenge 2

4. Resultados do Benchmark & Decisão Arquitetural

Evidências Empíricas das 81 Perguntas do Conjunto de Avaliação e Justificativa Técnica

4.1. Tabela Comparativa Consolidada de Resultados

A tabela a seguir apresenta os resultados obtidos na execução dos 4 testes sobre as 81 perguntas do conjunto de avaliação (3 repetições, base knowledge_base_v2, qwen3:8b), confrontando cada arquitetura com as metas; n/d = não medido:

Métrica Avaliada	Meta Quality Gate	Teste 1 (LLM Pura)	Teste 2 (RAG sem LLM)	Teste 3 (Naive RAG)	Teste 4 (Eleito) (Híbrido + Guardrails)
Recall@8 (leniente)	≥ 80,0%	N/A (sem base)	n/d	n/d	**63,9% [REPROV]**
artigo_esperado	≥ 80,0%	0,0% [REPROV]	30,5% [REPROV]	54,3% [REPROV]	**79,0% [REPROV]**
citacao_suportada	≥ 95,0%	0,0% [REPROV]	91,9% [REPROV]	95,3% [PASS]	**99,2% [PASS]**
Recusa fora do acervo	100,0%	0/27 [REPROV]	0/27 [REPROV]	0/27 [REPROV]	**27/27 [PASS]**
Clarify (acerto)	≥ 80,0%	0/30 [REPROV]	0/30 [REPROV]	0/30 [REPROV]	**30/30 [PASS]**
Latência mediana	≤ 5 s	2,76 s [PASS]	0,19 s [PASS]	1,60 s [PASS]	**2,22 s [PASS]**
Concordância da resposta	≥ 90,0%	69,5% [REPROV]	100,0% [PASS]	88,9% [REPROV]	**93,4% [PASS]**
Recusa indevida	≤ 5,0%	0/183 [PASS]	0/183 [PASS]	0/183 [PASS]	**15/183 [REPROV]**
Falso positivo	0	0/183 [PASS]	0/183 [PASS]	0/183 [PASS]	**15/183 [REPROV]**
Metas atingidas (medidas)	-	3 de 8	4 de 8	4 de 8	**5 de 9**

4.2. Análise Crítica dos Trade-offs e Variações Observadas

1. Inviabilidade da LLM pura no domínio contábil: O Teste 1 mostrou que a LLM isolada não serve para gestão fiscal: nenhum artigo esperado chega ao contexto (0,0%), nenhuma pergunta fora do acervo é recusada e a estabilidade entre repetições é a pior do conjunto (69,5%). Sem fonte, o usuário não consegue verificar a resposta e fica exposto a penalidades fiscais.

2. Insuficiência funcional do RAG sem LLM: O Teste 2 é o mais rápido (mediana de 0,19 s) e totalmente estável, mas entrega pouco valor: o artigo esperado chega ao contexto em 30,5% dos casos, o ROUGE-L é 0,066 e devolver trechos brutos de lei gera inércia e não resolve as dúvidas práticas do microempreendedor.

3. A fragilidade oculta do Naive RAG: O Teste 3 melhora muito sobre os anteriores (artigo esperado 54,3%, citações suportadas 95,3%), mas confiar só na busca vetorial densa perde o artigo certo com frequência: fica 25 pontos percentuais abaixo do RAG híbrido com reranker (79,0%).

4. O custo dos guardrails: Sem guardrails o sistema tem recusa fora do acervo 0/27, clarify 3/30 e artigo_esperado 79,4%. Com eles, a recusa vai a 27/27 e o clarify a 30/30, mas aparecem 15/183 recusas indevidas (8,2%, meta máxima de 5%), que antes constavam como respostas, e 15/183 falsos positivos (8,2%, meta 0). A pergunta do FGTS fica fora da conta de recusa: o gabarito pedia abstenção, mas a base cobre o tema (art. 10 do ADCT, na IN 2110/2022 e na IN 1922/2020). O artigo_esperado vai de 79,4% para 79,0% e o p95 chega a 12,62 s, tempo que pode ter sido inflado por carga na máquina.

4.3. Escolha Arquitetural: Por Que o Teste 4 É a Escolha Ótima para o Sócio Digital

O **Teste 4 (RAG Híbrido Avançado com Reranking e Guardrails Éticos)** foi selecionado como a arquitetura do produto. É a topologia com a melhor qualidade de resposta e de citação: **clarify de 30/30, 99,2% das citações suportadas pelo contexto e artigo esperado de 79,0% (meta: 80,0%)**, ROUGE-L de 0,217 e BERTScore de 0,548, com latência mediana de 2,22 s, dentro do limite de 5 s. Ao combinar a recuperação híbrida (esparsa + vetorial), a reordenação com cross-encoder, os guardrails de texto e a síntese controlada pelo prompt, o Sócio Digital oferece a melhor combinação de base legal e experiência didática entre as topologias testadas. Limitação assumida: o Recall@8 leniente (63,9%), as recusas indevidas (8,2%) e os falsos positivos (8,2%) ainda não atingem as metas, e a revisão humana independente das respostas segue pendente.

Residência Tecnológica em Inteligência Artificial (RES-IA) — Challenge 2

5. Governança MLOps, Links do Projeto & Conclusão

Rastreabilidade, Reprodutibilidade e Integração Contínua na Esteira de Produção

5.1. Esteira de CI/CD e Governança MLOps (Frente Ops — Ingrid Soares)

Para blindar o copiloto contra regressões em produção, a frente de DevOps & MLOps estruturou uma esteira de automação:
• **Quality Gate no GitHub Actions:** O script scripts/check_rag_regression.py roda automaticamente nos PRs, reprovando o build caso o Recall caia abaixo de 90% ou a Fidelidade caia abaixo de 99%.
• **Rastreamento de Experimentos no MLflow:** O script scripts/log_mlflow_benchmark.py registra parâmetros (Top-K, reranker score, temperatura) e métricas consolidadas em execuções auditáveis.
• **Versionamento de Dados com DVC:** Os arquivos do banco vetorial (vector_index.db.dvc) e da base fiscal (fiscal.db.dvc) são controlados via DVC com armazenamento remoto seguro.

5.2. Links Oficiais para o Projeto e Código-Fonte

Artefato / Recurso	Finalidade no Challenge 2	Link Permanente do Repositório
Repositório Principal	Código unificado do backend (FastAPI), frontend (Vite/React) e documentação.	https://github.com/ingrdsoares/RES-IA-Challenge-2
Suíte de Benchmark RAG	Script executável de benchmark quantitativo sobre os 35 casos do ground truth.	https://github.com/ingrdsoares/RES-IA-Challenge-2/blob/main/benchmark_rag.py
Quality Gate (CI/CD)	Script de verificação de limites de regressão e corte de pull request.	https://github.com/ingrdsoares/RES-IA-Challenge-2/blob/main/scripts/check_rag_regression.py
Módulo MLflow	Script de ingestão e governança de métricas históricas no MLflow Tracking.	https://github.com/ingrdsoares/RES-IA-Challenge-2/blob/main/scripts/log_mlflow_benchmark.py
Base Normativa & Docs	Especificação das fontes oficiais (LC 123, CGSN, Receita) e arquitetura de dados.	https://github.com/ingrdsoares/RES-IA-Challenge-2/blob/main/base_tributaria_ia_fontes_e_arquitetura.md

5.3. Cronograma e Próximos Passos (Semana 4)

Com a aprovação da arquitetura de RAG Híbrido Avançado na Semana 3, as prioridades para a Semana 4 compreendem: (1) Integrar a API otimizada à interface do usuário em React/Vite; (2) Implementar camada de cache semântico em Redis para respostas imediatas a consultas recorrentes de DAS; e (3) Conduzir testes com empreendedores reais para validação de impacto.

RESIDÊNCIA TECNOLÓGICA EM INTELIGÊNCIA ARTIFICIAL (RES-IA) — CHALLENGE 2
Entrega Oficial da Semana 3: Relatório Experimental LLM x RAG • Prazo de Conclusão: 13/11/2026
Grupo 08: Clara (Arquitetura) • Ingrid Soares (DevOps & MLOps) • Jhessica (Ciência de Dados) • Lucas (Engenharia de Dados) • Nasser (Arquitetura)