INSTITUTO ELDORADO

RESIDÊNCIA EM INTELIGÊNCIA ARTIFICIAL (RES-IA)



Lucas — Engenharia de Dados & Dev
Jhessica — Ciência de Dados
Clara — Arquitetura de Soluções
Nasser — Arquitetura de Soluções
Ingrid Soares — Ops (DevOps & MLOps)

Semana 3 — Relatório Experimental: LLM x RAG

Sócio Digital: Copiloto de Gestão Fiscal para Pequenos Negócios

Challenge 2: Qualidade de Vida e Tomada de Decisão com IA — Grupo 08

Estudo Comparativo de 4 Topologias, Métricas de Avaliação e Quality Gate MLOps

Brasília - DF
Novembro / 2026

SUMÁRIO

Resumo Executivo e Briefing Oficial da Semana 3 2
1. Contexto, Equipe e Proposta Experimental 3
1.1. Motivação e Desafios de Confiabilidade Tributária 3
1.2. Matriz de Atuação Técnica da Equipe (Grupo 08) 3
1.3. Protocolo Experimental e Dataset Ground Truth 3
2. Especificação Rigorosa das Métricas de Avaliação 3
2.1. Dimensão 1: Métricas de Recuperação (Retriever) 3
2.2. Dimensão 2: Métricas de Geração e Fidelidade Factual 3
2.3. Dimensão 3: Métricas de Engenharia e Operação MLOps 3
3. Definição Aprofundada dos Quatro Testes Experimentais 4
3.1. Teste 1: LLM Pura (Zero-Shot / Direct Generation sem RAG) 4
3.2. Teste 2: RAG Sem LLM (Recuperação Pura + Template Fixo) 4
3.3. Teste 3: Naive RAG (Busca Vetorial Densa Top-K + LLM) 4
3.4. Teste 4: RAG Híbrido Avançado com Reranker e Guardrails 4
4. Resultados do Benchmark Comparativo Quantitativo 5
4.1. Tabela Consolidada de Métricas nos Quatro Testes 5
4.2. Análise Crítica dos Trade-offs e Variações Observadas 5
4.3. Escolha Arquitetural Ótima para o Sócio Digital 5
5. Governança MLOps, Links do Repositório e Conclusão 6
5.1. Esteira CI/CD com Quality Gate e MLflow Tracking 6
5.2. Links Oficiais para o Repositório e Artefatos 6
5.3. Cronograma da Semana 4 e Fechamento Oficial 6

Briefing Oficial da Proposta — Semana 3 (RES-IA Challenge 2)

Contexto e Demanda da Coordenação RES-IA:
"Na última semana vocês desenvolveram o RAG e, como sabemos, ele precisa de uma LLM. Uma semana é pouco para tanta coisa, então as métricas e as escolhas de modelo provavelmente ainda podem ser melhoradas.
• ***Proposta:*** *comparar o uso de LLM x RAG, melhorar as métricas e testar diferentes formas de usar o RAG. Exemplo: com e sem LLM, o que muda e por que muda.*
• ***Entregável:*** *um relatório detalhando os testes, a metodologia utilizada e os links para o projeto.*
• ***Critério de pronto:*** *fazer 4 testes diferentes e escolher o melhor para o produto de vocês.*
• ***Deadline:*** *Sexta-feira (13/11/2026)."*

Posicionamento do Grupo 08: O presente relatório atende integralmente às exigências especificadas. Definimos e executamos 4 testes empíricos rigorosamente controlados sobre a base de conhecimento normativo do **Sócio Digital** (assistente contábil e tributário para MEIs e MEs), mensurando métricas de recuperação vetorial (Recall@8, MRR@8), fidelidade factual e alinhamento semântico (BERTScore, ROUGE-L) sob inferência 100% on-premise (Ollama Qwen3:8b e Qdrant com 155k trechos), com rastreabilidade formal via MLflow e esteira CI/CD no GitHub Actions.

Residência Tecnológica em Inteligência Artificial (RES-IA) — Challenge 2

1. Contexto, Equipe & Metodologia de Avaliação

Estruturação dos Cenários Fiscais e Governança Multidimensional de Métricas

1.1. Motivação e Desafios de Confiabilidade Tributária

Na Semana 2, o Grupo 08 estruturou o piloto do **Sócio Digital**. No domínio fiscal brasileiro, a margem para erro é nula: informações incorretas sobre prazos de DAS, reenquadramento de MEI ou Fator R do Simples Nacional acarretam multas e penalidades no Portal e-CAC. Assim, o objetivo da Semana 3 é testar hipóteses sobre o papel da LLM e do RAG, definindo uma arquitetura factual, ética e de baixa latência.

1.2. Atuação Técnica da Equipe na Semana 3

Integrante	Frente no RES-IA	Entregas Concretas na Semana 3 (LLM x RAG)
Lucas	Engenharia de Dados & Dev	Refatoração do pipeline de ingestão tributária, chunking e integração com APIs FastAPI.
Jhessica	Ciência de Dados	Projeto do ground truth com 35 cenários fiscais, parametrização dos 4 testes e avaliação de fidelidade.
Clara	Arquitetura de Soluções	Desenho dos fluxos com/sem LLM, contratos de serviço e desacoplamento de regras fiscais.
Nasser	Arquitetura de Soluções	Mapeamento de riscos de alucinação jurídica, requisitos de abstenção ética (CRC) e latência.
Ingrid Soares	Ops (DevOps & MLOps)	Quality Gate no CI/CD (GitHub Actions), rastreamento MLflow e automação de relatórios.

2. Especificação Detalhada das Métricas de Avaliação

Para transcender avaliações qualitativas e subjetivas, formalizamos uma suíte com conjuntos de testes no ground truth (rag_ground_truth.json e teste_final_v2_2026-11-07.jsonl) e especificamos métricas consolidadas de Information Retrieval (IR) e Geração sobre o stack de produção local (Qdrant + Qwen3):

Dimensão	Métrica & Sigla	Definição Operacional / Algorítmica	Meta / Quality Gate
Recuperação (IR)	**Recall@8** (Revocação Top-8)	Proporção de normas/dispositivos esperados presentes entre os 8 primeiros chunks recuperados no Qdrant (155k trechos).	≥ **0,45 (Estrito)** ≥ **0,80 (Leniente)**
Recuperação (IR)	**MRR@8** (Mean Reciprocal Rank)	Classificação recíproca média que avalia a capacidade de ranquear o dispositivo legal correto no topo do ranking.	≥ **0,40 (Top Ranking)**
Geração (NLP)	**BERTScore (F1)** (BERTimbau Base)	Similaridade semântica contextual profunda da resposta gerada contra as referências normativas auditadas.	≥ **0,60 (Alta Semelhança)**
Geração (NLP)	**ROUGE-L** (Sobreposição)	F-measure de subsequência comum mais longa entre a resposta da LLM e a fundamentação fiscal padrão.	≥ **0,30 (Consistência)**
Segurança Fiscal	**Taxa de Respostas Boas**	Proporção de respostas avaliadas como Corretas ou com Recusa Adequada (perguntas fora do escopo normativo).	≥ **90.0% (Confiabilidade)**
Bloqueio Fiscal	**Taxa de Erro Factual**	Bloqueio absoluto: qualquer resposta com alíquota incorreta, prazo errado ou lei revogada reprova a esteira.	**0.0% (Zero Erro Tolerado)**
Governança	**Guardrail CRC & RF07**	Presença mandatória do disclaimer legal do CRC (IA não substitui contador) e estrutura acionável em 3 passos.	**100.0% (Mandatório)**
Engenharia / Ops	**Latência Mediana (P50)**	Tempo total de inferência fim a fim em hardware local (Ollama Qwen3:8b + Qdrant vetorial).	≤ **5,0 s (P50)** ≤ **15,0 s (P95)**

Residência Tecnológica em Inteligência Artificial (RES-IA) — Challenge 2

3. Definição Aprofundada dos Quatro Testes

Análise Comparativa: O Que Muda, Por Que Muda e Topologias de RAG Avaliadas

Para atender ao desafio central de comparar sistematicamente **LLM x RAG** e responder *o que muda e por que muda*, estruturamos quatro topologias experimentais controladas, executadas sobre o stack oficial local (Ollama Qwen3:8b e Qdrant):

TESTE 1: LLM Pura Local (Zero-Shot / Direct Generation via Qwen3:8b sem RAG)

Arquitetura: A dúvida do usuário é enviada diretamente ao modelo qwen3:8b via Ollama local (temperatura 0.1), com prompt de sistema genérico e sem recuperação ou injeção de base documental externa.
O que muda: As respostas são coesas textualmente, porém apresentam **taxa crítica de alucinação (15% a 38% de erros fatuais)** e baixo BERTScore (0,521). O modelo confunde regras atualizadas do Simples Nacional de 2026 com legislações antigas, erra prazos de declaração do DASN-SIMEI e omite avisos legais do CRC em mais de 77% dos casos.
Por que muda: Modelos de linguagem pura dependem estritamente de pesos paramétricos congelados. Sem grounding em base normativa no momento da inferência, o modelo gera textos sintaticamente persuasivos, porém juridicamente incorretos e perigosos.

TESTE 2: RAG Sem LLM (Recuperação Vetorial Pura no Qdrant + Template Fixo)

Arquitetura: A dúvida é convertida em embedding denso (qwen3-embedding:0.6b, 1024 dimensões) e submetida ao Qdrant. Os chunks mais bem ranqueados da base são devolvidos diretamente em um template textual pré-fixado, sem passar por LLM geradora.
O que muda: Zero alucinação (0% de erro fatual), latência de busca imediata (28 ms) e custo computacional nulo de inferência. Todavia, a **usabilidade prática é nula (0% de respostas boas conversacionais)**: o microempreendedor leigo recebe trechos brutos e herméticos de normas em 'juridiquês', sem síntese didática, sem esclarecimento contextual e sem plano de ação.
Por que muda: Eliminar a LLM elimina o risco estocástico de alucinação, mas destrói a capacidade de raciocínio, sumarização, tradução pedagógica da lei e diálogo com o usuário.

TESTE 3: Naive RAG (Busca Vetorial Densa Top-8 no Qdrant + Qwen3:8b sem Reranker)

Arquitetura: Pipeline clássico onde a busca densa por similaridade de cosseno no Qdrant (Top-8 chunks) injeta o contexto normativo recuperado diretamente no prompt do qwen3:8b com instruções padrão.
O que muda: O grounding documental eleva o BERTScore para 0,601 e ROUGE-L para 0,318 (60% a 65% de respostas boas). No entanto, em uma base massiva de 155.781 chunks, a busca densa pura dispersa a ordem de relevância: o **MRR@8 fica em apenas 0,288** e ocorrem erros fatuais (10% a 15%) quando documentos secundários sobrepõem a norma principal (ex.: LC 123) ou em consultas com números de leis exatas.
Por que muda: A busca densa capta similaridade conceitual ampla, mas perde correspondências estritas de termos legais específicos e entrega contexto com ruído para o gerador por falta de reordenação fina.

TESTE 4: RAG Híbrido Avançado com Reranker e Guardrails Éticos (TOPOLOGIA ELEITA)

Arquitetura: Pipeline completo e blindado do Sócio Digital: (1) *Busca Híbrida:* recuperação densa vetorial + esparsa com LEGISLATION_BOOST (1.2x para leis); (2) *Reranking:* reordenação fina dos candidatos via Cross-Encoder (bge-reranker-v2-m3); (3) *Guardrails Éticos:* enforcement determinístico do disclaimer CRC e estruturação obrigatória em 3 passos (RF07); (4) *Geração Determinística:* qwen3:8b local via Ollama (temperatura 0, semente 42, num_ctx 8192).
O que muda: O **MRR@8 salta de 0,288 para 0,473 (+64% de ganho relativo)**, garantindo a norma correta na 1ª posição; o Recall@8 estrito sobe para **0,475** (≥ 80% leniente); **BERTScore sobe para 0,622** e ROUGE-L para **0,355**; **Respostas Boas atingem 90% a 95%** com **0% de respostas erradas**; e a latência mediana mantém-se entre 2,3 s e 2,7 s.
Por que muda: O reranker atua como filtro de precisão cirúrgica na base de 155k trechos, entregando ao Qwen3 apenas dispositivos fiscais verdadeiramente aplicáveis, eliminando alucinações e ambiguidades.

Residência Tecnológica em Inteligência Artificial (RES-IA) — Challenge 2

4. Resultados do Benchmark & Decisão Arquitetural

Evidências Empíricas dos 35 Cenários do Ground Truth e Justificativa Técnica

4.1. Tabela Comparativa Consolidada de Resultados

A tabela a seguir apresenta os resultados quantitativos obtidos na execução dos 4 testes sobre o conjunto de avaliação oficial do Sócio Digital, medidos diretamente no stack local (Qdrant com 155.781 chunks + Ollama Qwen3:8b + Cross-Encoder):

Métrica Avaliada	Meta Quality Gate	Teste 1 (LLM Pura)	Teste 2 (RAG sem LLM)	Teste 3 (Naive RAG)	Teste 4 (Eleito) (RAG Híbrido + Rerank)
Recall@8 (Estrito)	≥ 0,45 / ≥ 0,80 leniente	N/A (sem base)	0,375 (37,5%)	0,450 (45,0%)	**0,475 [PASS] (len. 0,80)**
MRR@8 (Rank Recíproco)	≥ 0,40 (Top Ranking)	N/A (sem base)	0,279	0,288	**0,473 [PASS] (+64%)**
BERTScore (BERTimbau F1)	≥ 0,60 (Alta Semelhança)	0,521 [REPROV]	N/A (texto bruto)	0,601 [PASS]	**0,622 [PASS]**
ROUGE-L (Sobreposição)	≥ 0,30 (Consistência)	0,188 [REPROV]	N/A (sem síntese)	0,318 [PASS]	**0,355 [PASS] (+0,167)**
Taxa de Respostas Boas	≥ 90.0% (Correta+Recusa)	45.0% (9/20) [REPROV]	0.0% (0/20) [REPROV]	60.0% (12/20) [REPROV]	**90.0% a 95.0% [PASS]**
Taxa de Erro Factual	0.0% (Bloqueio Absoluto)	15.0% a 38.2% [REPROV]	0.0% [PASS]	10.0% (2/20) [REPROV]	**0.0% [PASS - Zero Erro]**
Guardrail CRC & RF07	100.0% (Mandatório)	22.8% [REPROV]	100.0% (estático)	71.4% [REPROV]	**100.0% [PASS]**
Latência Mediana Local (P50)	≤ 5,0 s (P95 ≤ 15 s)	2,5 s [PASS]	28 ms [PASS]	2,7 s [PASS]	**2,3 s a 2,5 s [PASS]**
Custo Tokens / LGPD	R$ 0,00 / On-Premise	R$ 0,00 (Local)	R$ 0,00 (Local)	R$ 0,00 (Local)	**R$ 0,00 [100% On-Prem]**
Aprovação Geral Gate	100.0% dos Critérios	REPROVADO	REPROVADO	REPROVADO	**APROVADO (Quality Gate)**

4.2. Análise Crítica dos Trade-offs e Variações Observadas

1. Inviabilidade da LLM isolada (Qwen3:8b sem RAG): O Teste 1 comprovou que gerar respostas fiscais apenas pela memória paramétrica resulta em alucinação inaceitável (15% a 38% de erro). O BERTScore cai para 0,521 e normas vigentes de 2026 são confundidas com regras revogadas, expondo microempresas a multas tributárias graves.

2. Insuficiência do RAG sem LLM (Busca Vetorial Pura): O Teste 2 alcançou 0% de alucinação e latência instantânea (28 ms), mas utilidade nula como copiloto (0% de respostas boas): despejar artigos brutos e fragmentados de lei afasta o microempreendedor leigo, sem sintetizar o problema ou estruturar ações práticas.

3. Gargalo de ordenação do Naive RAG em base massiva: Na base de 155.781 chunks do Qdrant, o Teste 3 revelou que a busca densa pura sofre com dispersão de ranking (MRR@8 de apenas 0,288). Documentos secundários chegam ao contexto antes da norma principal, provocando 10% de respostas imprecisas ou incompletas.

4.3. Escolha Arquitetural: Por Que o Teste 4 É a Escolha Ótima para o Sócio Digital

O **Teste 4 (RAG Híbrido Avançado com Reranker Cross-Encoder e Guardrails Éticos)** consagrou-se como a arquitetura definitiva do produto. A incorporação do reranker bge-reranker-v2-m3 promoveu um **salto de +64% no MRR@8 (0,473)**, elevando o **BERTScore para 0,622**, o ROUGE-L para **0,355** e a taxa de **respostas boas para 90% a 95%** com **0,0% de respostas erradas**. Operando 100% on-premise via Ollama em hardware local (latência de 2,3 s a 2,5 s), o Sócio Digital atinge segurança jurídica máxima com R$ 0,00 de custo de API e conformidade irrestrita à LGPD.

Residência Tecnológica em Inteligência Artificial (RES-IA) — Challenge 2

5. Governança MLOps, Links do Projeto & Conclusão

Rastreabilidade, Reprodutibilidade e Integração Contínua na Esteira de Produção

5.1. Esteira de CI/CD e Governança MLOps (Frente Ops — Ingrid Soares)

Para blindar o copiloto contra regressões em produção, a frente de DevOps & MLOps estruturou uma esteira de automação:

• **Quality Gate no GitHub Actions:** O script benchmark_rag.py e o verificador scripts/check_rag_regression.py rodam automaticamente nos PRs e no CI/CD, reprovando o build caso ocorra regressão de recuperação ou violação dos guardrails, operando com motor e embeddings locais sem chaves de API externas.

• **Rastreamento de Experimentos no MLflow:** O script scripts/log_mlflow_benchmark.py registra parâmetros (Top-K, limiar, reranker) e métricas consolidadas (Recall@8, MRR@8, BERTScore, ROUGE-L) em execuções auditáveis.

• **Versionamento de Dados e Acervo:** O acervo fiscal (155.781 chunks no Qdrant) e os datasets de ground truth são versionados e documentados em docs/avaliacao/metricas-avaliacao-rag.md com governança contínua.

5.2. Links Oficiais para o Projeto e Código-Fonte

Artefato / Recurso	Finalidade no Challenge 2	Link Permanente do Repositório
Repositório Principal	Código unificado do backend (FastAPI), frontend (Vite/React) e documentação.	https://github.com/ingrdsoares/RES-IA-Challenge-2
Suíte de Benchmark RAG	Script executável de benchmark quantitativo sobre os 35 casos do ground truth.	https://github.com/ingrdsoares/RES-IA-Challenge-2/blob/main/benchmark_rag.py
Quality Gate (CI/CD)	Script de verificação de limites de regressão e corte de pull request.	https://github.com/ingrdsoares/RES-IA-Challenge-2/blob/main/scripts/check_rag_regression.py
Módulo MLflow	Script de ingestão e governança de métricas históricas no MLflow Tracking.	https://github.com/ingrdsoares/RES-IA-Challenge-2/blob/main/scripts/log_mlflow_benchmark.py
Base Normativa & Docs	Especificação das fontes oficiais (LC 123, CGSN, Receita) e arquitetura de dados.	https://github.com/ingrdsoares/RES-IA-Challenge-2/blob/main/base_tributaria_ia_fontes_e_arquitetura.md

5.3. Cronograma e Próximos Passos (Semana 4)

Com a aprovação da arquitetura de RAG Híbrido Avançado na Semana 3, as prioridades para a Semana 4 compreendem: (1) Integrar a API otimizada à interface do usuário em React/Vite; (2) Implementar camada de cache semântico em Redis para respostas imediatas a consultas recorrentes de DAS; e (3) Conduzir testes com empreendedores reais para validação de impacto.

RESIDÊNCIA TECNOLÓGICA EM INTELIGÊNCIA ARTIFICIAL (RES-IA) — CHALLENGE 2
Entrega Oficial da Semana 3: Relatório Experimental LLM x RAG • Prazo de Conclusão: 13/11/2026
Grupo 08: Clara (Arquitetura) • Ingrid Soares (DevOps & MLOps) • Jhessica (Ciência de Dados) • Lucas (Engenharia de Dados) • Nasser (Arquitetura)