Plano da entrega de segunda-feira

Sócio Digital · Grupo 08 · RES-IA Challenge 2 · Versão de 06/11/2026 · Prazo: 09/11/2026, às 8h00, na pasta da equipe no Teams, canal Segundo Desafio

Em resumo. A maior parte das peças já existe, mas o caminho completo (base → Qdrant → resposta com fontes) nunca rodou de ponta a ponta. O primeiro passo é esse teste. A avaliação olha a qualidade da recuperação, a fundamentação das respostas e a rastreabilidade das fontes, não a interface. Por isso, todo o esforço do grupo vai para esses três pontos.

1. Onde os modelos vão rodar

Numa máquina do Lucas com RTX 3080 Ti e 32 GB de RAM, que já tem o Qwen instalado. Falta conferir se as versões são as que a API usa (qwen3:8b e qwen3-embedding:0.6b, 1024 dimensões), se o Docker está pronto e levar para lá a branch do recorte e a base. A coleta e o refino seguem em outra máquina. Indexar, medir e gerar as consultas da demonstração passam por essa máquina.

2. O que foi pedido e onde estamos

Item pedido	Situação	Onde estamos	O que falta
Base curada, mínimo de 20 documentos	**Parcial**	Recorte com 4.811 documentos, com hash registrado.	Congelar a versão e escolher o recorte.
Estratégia de chunking	**Parcial**	Implementada: hierárquico jurídico, até 2.000 caracteres, sobreposição de 200.	Escrever o documento.
Estratégia de embeddings	**Parcial**	Definida: qwen3-embedding:0.6b, 1024 dimensões, cosseno.	Escrever o documento e atualizar o README de src/rag, que ainda cita MiniLM.
Banco vetorial	**Parcial**	Qdrant e script de carga prontos, em branch local do Lucas, ainda não publicada.	Publicar, revisar e carregar a base. A coleção está vazia.
Consulta, chunks recuperados e resposta	**Parcial**	Rota /rag/query existe, mas nunca rodou com esta base.	Teste de ponta a ponta.
Evidência das fontes	**Parcial**	A resposta prevê fonte, score, document_id e chunk_id.	Confirmar numa resposta real.
Diagrama de arquitetura	**Falta**	Diagrama do Excalidraw no PR #8, como arquitetura-alvo; não mostra Ollama nem o refino.	Fazer a versão só com o que foi implementado.
Pipeline de ingestão	**Falta**	Sem documento único.	Descrever: coleta → refino → recorte → chunks → embeddings → Qdrant.

3. Decisões propostas

- **Caminho oficial:** Qdrant com a API de backend/api. O RAG em src/rag (SQLite, respostas por template, sem LLM) não entra na demo.
- **Refino:** continua em andamento e não bloqueia a entrega. A base congela quando o teste de ponta a ponta passar, usando a versão validada que existir nesse momento. Uma versão posterior fica para a próxima etapa.
- **Base da demo:** começar pelas frentes centrais, que somam 46 documentos: legislação, legislação complementar, manuais, MEI, SPED, ISS/DF, lucro presumido, calendário DF e jurisprudência. Cumpre o mínimo com folga e facilita avaliar a recuperação.
- **Fora desta entrega:** frontend, autenticação, MLflow e testes com usuários.

4. Tarefas, por ordem de dependência

As tarefas da etapa 1 podem começar juntas. O único horário fixo é o prazo final.

Etapa	Quem	Tarefa	Depende de	Pronta quando
1	Lucas	Publicar a branch do recorte e abrir o PR. Na máquina da RTX 3080 Ti: conferir modelos e Docker, levar o CSV conferindo o hash e testar com 20 documentos.	Nada	Uma consulta retorna resposta com chunks e fontes reais.
1	Clara e Nasser	Fazer o diagrama do que foi implementado (base: Excalidraw do PR #8) e o documento do pipeline.	Nada	Os dois refletem o sistema real, com Qdrant e Ollama.
1	Jhessica	Escrever a estratégia de chunking e a de embeddings. Criar de 20 a 30 perguntas com a fonte esperada. Escrever o documento de métricas: fórmulas e metas de Recall@k e MRR por documento, confirmando se as metas antigas (90% e 85%) valem.	Nada	Documentos revisados; perguntas com fonte conferida; métricas e metas definidas.
2	Ingrid	Revisar o PR e o README de execução. Conferir que API e Qdrant sobem em outra máquina (sem os modelos, /ready responde 503).	PR da etapa 1	README cobre a máquina usada e o compose sobe fora dela.
3	Lucas	Congelar a base, indexar e gerar a lista dos documentos-fonte.	Teste da etapa 1	Coleção carregada; lista e hash publicados para o grupo.
4	Jhessica	Implementar a medição, comparando a fonte esperada com o document_id dos chunks. Definir as rodadas de TOP_K e SCORE_THRESHOLD (o 0,5 atual nunca foi calibrado).	Etapa 1	Script e lista de rodadas entregues ao Lucas.
5	Lucas	Rodar as medições na máquina da RTX 3080 Ti.	Etapas 3 e 4	Resultados de cada rodada em arquivo.
6	Jhessica	Analisar Recall@k e MRR, comparar às metas e definir os parâmetros finais.	Etapa 5	Análise escrita e parâmetros finais definidos.
7	Ingrid	Escolher as perguntas da demonstração, incluindo uma sem resposta na base.	Etapa 3	Lista de perguntas entregue ao Lucas.
8	Lucas	Aplicar os parâmetros finais, rodar as perguntas e guardar as saídas da API.	Etapas 6 e 7	Saídas com chunks, resposta e fontes em arquivo.
9	Ingrid	Montar o relatório em PDF da demonstração: pergunta, chunks, resposta e fontes.	Etapa 8	Relatório mostra os quatro itens com saídas reais da API.
10	Ingrid	Montar a pasta da entrega e enviar no Teams.	Todas as anteriores	Lista da seção 5 conferida e arquivos na pasta.

5. O que vai na pasta do Teams

- Lista dos documentos-fonte, manifesto com hash e o recorte usado.
- Estratégia de chunking e estratégia de embeddings.
- Link do repositório com a implementação do banco vetorial.
- Relatório da demonstração em PDF, com as saídas da API em anexo.
- Diagrama do que foi implementado, arquitetura-alvo e documento do pipeline de ingestão.
- Extras que sustentam o foco da etapa: documento de métricas e resultados da avaliação.

6. Cuidados

- **Máquina única:** guardar cada resultado assim que sair (snapshot do Qdrant, medições e saídas da API).
- **Vigência:** vigencia_fonte pode vir vazio; mostrar a data de coleta, sem afirmar que a norma está vigente.
- **Tamanho:** o recorte completo tem 191 MB; enviar ao Teams o recorte menor, com a lista e o manifesto.
- **Formato da demo:** o pedido não define o formato; confirmar com quem avalia se o relatório em PDF atende.
- **Métricas antigas:** os 100% de benchmark-rag-mlops.md medem o RAG por template; não usar aqui.