Planejamento de Etapas

Etapa 2: Confiabilidade do RAG

Sócio Digital: Copiloto de Gestão Fiscal para Pequenos Negócios

Objetivo

Tornar a qualidade das respostas verificável por terceiros e adequada para uso real: gabarito revisado, casos críticos corrigidos, proteções em produção e suporte a vários usuários ao mesmo tempo.

Ponto de partida

A avaliação de 07/11/2026 mostra 17 de 20 perguntas novas corretas ou com recusa adequada. A classificação é preliminar: foi feita pela equipe que escreveu as perguntas, e q07, q13 e q20 ainda erram. A API atende uma consulta por vez por processo e não tem streaming.

Resultado esperado

Resultado de qualidade validado de forma independente, guardrails ativos e API pronta para uso simultâneo.

Resumo das issues

ID	Issue	Prioridade	Responsável sugerido
E2.1	Revisão independente do gabarito de avaliação	Alta	Jhessica (coordena); revisor externo com perfil contábil
E2.2	Congelar um conjunto de teste separado dos ajustes	Alta	Jhessica
E2.3	Corrigir as respostas de q07, q13 e q20	Alta	Jhessica
E2.4	Guardrails em produção: aviso do CRC, fraude e abstenção	Alta	Jhessica e Clara
E2.5	Streaming da resposta	Média	Lucas
E2.6	Atender consultas simultâneas	Alta	Lucas
E2.7	Rodar a medição de qualidade no CI	Média	Ingrid

Cada issue abaixo está escrita para ser copiada ao GitHub: o título da seção vira o título da issue; os rótulos indicados devem ser criados no repositório; a descrição e os critérios de aceite vão no corpo. Responsáveis e prioridades são sugestões e devem ser confirmados pela equipe.

Issues

[E2.1] Revisão independente do gabarito de avaliação

Responsável sugerido: Jhessica (coordena); revisor externo com perfil contábil

Prioridade: Alta

Rótulos: etapa-2, avaliação, qualidade

Depende de: Nenhuma

Descrição

Obter a revisão de uma pessoa que não escreveu as perguntas, preferencialmente com formação contábil/fiscal, sobre as perguntas, as referências e a classificação das respostas (correta, parcial, errada, recusa). Registrar divergências e quem revisou.

Critérios de aceite

- Todas as perguntas do teste novo revisadas
- Divergências registradas e resolvidas no gabarito
- Relatório atualizado indicando que a classificação foi revisada e por quem

---

[E2.2] Congelar um conjunto de teste separado dos ajustes

Responsável sugerido: Jhessica

Prioridade: Alta

Rótulos: etapa-2, avaliação

Depende de: Revisão independente do gabarito

Descrição

Separar um conjunto de validação que não será usado para ajustar prompts e parâmetros, versionado com hash. As 25 perguntas de desenvolvimento ficam só para ajuste.

Critérios de aceite

- Conjunto congelado versionado e documentado
- Regra no README de avaliação: não ajustar olhando este conjunto
- Comando único que reproduz a medição

[E2.3] Corrigir as respostas de q07, q13 e q20

Responsável sugerido: Jhessica

Prioridade: Alta

Rótulos: etapa-2, ia, bug

Depende de: Nenhuma

Descrição

q13 não cita o efeito retroativo do desenquadramento; q20 abre negando a continuidade do tratamento simplificado; q21 explica pior a não cumulatividade. Investigar recuperação, prompt e acervo e corrigir sem regredir as demais.

Critérios de aceite

- Causa de cada erro identificada e registrada
- As três respostas corrigidas ou a lacuna do acervo documentada
- Nenhuma pergunta do conjunto de desenvolvimento piora

[E2.4] Guardrails em produção: aviso do CRC, fraude e abstenção

Responsável sugerido: Jhessica e Clara | **Prioridade:** Alta

Rótulos: etapa-2, ia, segurança | **Depende de:** Nenhuma

Descrição

Garantir que toda resposta traga o aviso de que o produto não substitui contador, que pedidos de evasão ou fraude sejam recusados e que a falta de base resulte em abstenção. Portar os cenários de governança de src/rag para o backend atual.

Critérios de aceite

- Aviso presente em toda resposta fiscal
- Casos de fraude e de falta de base cobertos por testes
- Texto do aviso validado por quem responde pela fronteira ética (CRC/LGPD)

[E2.5] Streaming da resposta

Responsável sugerido: Lucas | **Prioridade:** Média

Rótulos: etapa-2, backend, feature | **Depende de:** Nenhuma

Descrição

Entregar a resposta em fluxo (SSE ou equivalente) para reduzir a espera percebida. As fontes e o status devem chegar de forma consistente com a resposta completa.

Critérios de aceite

- Endpoint de streaming documentado
- Fontes enviadas ao final ou no início, de forma definida
- Erros no meio do fluxo tratados e sinalizados ao cliente

[E2.6] Atender consultas simultâneas

Responsável sugerido: Lucas | **Prioridade:** Alta

Rótulos: etapa-2, backend, desempenho | **Depende de:** Decisão de hospedagem do LLM (etapa 4) influencia o limite

Descrição

Hoje pedidos simultâneos recebem 503 e a execução exige um único worker. Introduzir fila ou limite de concorrência controlado e medir o impacto no Ollama ou no serviço de LLM escolhido.

Critérios de aceite

- Duas ou mais consultas simultâneas concluem sem 503 dentro do limite definido
- Limite e comportamento de fila documentados
- Teste de concorrência automatizado

[E2.7] Rodar a medição de qualidade no CI

Responsável sugerido: Ingrid	**Prioridade:** Média
Rótulos: etapa-2, ci, avaliação	**Depende de:** Conjunto de teste congelado

Descrição

Executar uma verificação de qualidade (conjunto reduzido e determinístico) a cada mudança em prompts, recuperação ou acervo, falhando o CI se houver queda além de um limite acordado.

Critérios de aceite

- Job de qualidade no workflow
- Limite de regressão definido e documentado
- Relatório anexado à execução