Planejamento de Etapas

Etapa 2: Confiabilidade do RAG

Sócio Digital: Copiloto de Gestão Fiscal para Pequenos Negócios

Objetivo

Tornar a qualidade das respostas verificável por terceiros e adequada para uso real: gabarito revisado, casos críticos corrigidos, proteções em produção e suporte a vários usuários ao mesmo tempo.

Ponto de partida

A avaliação de 07/11/2026 mostra 17 de 20 perguntas novas corretas ou com recusa adequada. A classificação é preliminar: foi feita pela equipe que escreveu as perguntas, e q07, q13 e q20 ainda erram. A API atende uma consulta por vez por processo e não tem streaming.

Resultado esperado

Resultado de qualidade validado de forma independente, guardrails ativos e API pronta para uso simultâneo.

Resumo das issues

ID	Issue	Prioridade
E2.1	Revisão independente do gabarito de avaliação	Alta
E2.2	Congelar um conjunto de teste separado dos ajustes	Alta
E2.3	Corrigir as respostas de q07, q13 e q20	Alta
E2.4	Guardrails em produção: aviso do CRC, fraude e abstenção	Alta
E2.5	Streaming da resposta	Média
E2.6	Atender consultas simultâneas	Alta
E2.7	Rodar a medição de qualidade no CI	Média
E2.8	Testes adversariais: injeção de prompt e vazamento de contexto	Alta

Cada issue abaixo está escrita para ser copiada ao GitHub: o título da seção vira o título da issue; os rótulos indicados devem ser criados no repositório; a descrição e os critérios de aceite vão no corpo. Não há responsável fixo: quem pegar a tarefa se atribui no GitHub. As prioridades são sugestões e devem ser confirmadas pela equipe.

Issues

[E2.1] Revisão independente do gabarito de avaliação

Quem assume: a definir (atribuir no GitHub) | **Prioridade:** Alta

Rótulos: etapa-2, avaliação, qualidade | **Depende de:** Nenhuma

Descrição

Obter a revisão de uma pessoa que não escreveu as perguntas, preferencialmente com formação contábil/fiscal, sobre as perguntas, as referências e a classificação das respostas (correta, parcial, errada, recusa). Registrar divergências e quem revisou.

Critérios de aceite

- Todas as perguntas do teste novo revisadas
- Divergências registradas e resolvidas no gabarito
- Relatório atualizado indicando que a classificação foi revisada e por quem

---

[E2.2] Congelar um conjunto de teste separado dos ajustes

Quem assume: a definir (atribuir no GitHub) | **Prioridade:** Alta

Rótulos: etapa-2, avaliação | **Depende de:** Revisão independente do gabarito

Descrição

Separar um conjunto de validação que não será usado para ajustar prompts e parâmetros, versionado com hash. As 25 perguntas de desenvolvimento ficam só para ajuste.

Critérios de aceite

- Conjunto congelado versionado e documentado
- Regra no README de avaliação: não ajustar olhando este conjunto
- Comando único que reproduz a medição

[E2.3] Corrigir as respostas de q07, q13 e q20

Quem assume: a definir (atribuir no GitHub) | **Prioridade:** Alta

Rótulos: etapa-2, ia, bug | **Depende de:** Nenhuma

Descrição

q13 não cita o efeito retroativo do desenquadramento; q20 abre negando a continuidade do tratamento simplificado; q21 explica pior a não cumulatividade. Investigar recuperação, prompt e acervo e corrigir sem regredir as demais.

Critérios de aceite

- Causa de cada erro identificada e registrada
- As três respostas corrigidas ou a lacuna do acervo documentada
- Nenhuma pergunta do conjunto de desenvolvimento piora

[E2.4] Guardrails em produção: aviso do CRC, fraude e abstenção

Quem assume: a definir (atribuir no GitHub)	**Prioridade:** Alta
Rótulos: etapa-2, ia, segurança	**Depende de:** Nenhuma

Descrição

Garantir que toda resposta traga o aviso de que o produto não substitui contador, que pedidos de evasão ou fraude sejam recusados e que a falta de base resulte em abstenção. Portar os cenários de governança de src/rag para o backend atual.

Critérios de aceite

- Aviso presente em toda resposta fiscal
- Casos de fraude e de falta de base cobertos por testes
- Texto do aviso validado por quem responde pela fronteira ética (CRC/LGPD)

[E2.5] Streaming da resposta

Quem assume: a definir (atribuir no GitHub)	**Prioridade:** Média
Rótulos: etapa-2, backend, feature	**Depende de:** Nenhuma

Descrição

Entregar a resposta em fluxo (SSE ou equivalente) para reduzir a espera percebida. As fontes e o status devem chegar de forma consistente com a resposta completa.

Critérios de aceite

- Endpoint de streaming documentado
- Fontes enviadas ao final ou no início, de forma definida
- Erros no meio do fluxo tratados e sinalizados ao cliente

[E2.6] Atender consultas simultâneas

Quem assume: a definir (atribuir no GitHub)	**Prioridade:** Alta
Rótulos: etapa-2, backend, desempenho	**Depende de:** Decisão de hospedagem do LLM (etapa 4) influencia o limite

Descrição

Hoje pedidos simultâneos recebem 503 e a execução exige um único worker. Introduzir fila ou limite de concorrência controlado e medir o impacto no Ollama ou no serviço de LLM escolhido.

Critérios de aceite

- Duas ou mais consultas simultâneas concluem sem 503 dentro do limite definido
- Limite e comportamento de fila documentados
- Teste de concorrência automatizado

[E2.7] Rodar a medição de qualidade no CI

Quem assume: a definir (atribuir no GitHub) **Prioridade:** Média

Rótulos: etapa-2, ci, avaliação **Depende de:** Conjunto de teste congelado

Descrição

Executar uma verificação de qualidade (conjunto reduzido e determinístico) a cada mudança em prompts, recuperação ou acervo, falhando o CI se houver queda além de um limite acordado.

Critérios de aceite

- Job de qualidade no workflow
- Limite de regressão definido e documentado
- Relatório anexado à execução

[E2.8] Testes adversariais: injeção de prompt e vazamento de contexto

Quem assume: a definir (atribuir no GitHub) **Prioridade:** Alta

Rótulos: etapa-2, segurança, ia **Depende de:** Guardrails em produção

Descrição

Criar um conjunto de ataques ao assistente: instruções escondidas em perguntas, pedidos para ignorar regras, tentativa de obter o prompt do sistema ou dados de outra empresa, e conteúdo malicioso vindo de documentos do acervo. Medir e corrigir as falhas.

Critérios de aceite

- Conjunto de ataques versionado, com resultado esperado por caso
- Falhas encontradas registradas e corrigidas ou aceitas com justificativa
- Execução automatizada, de preferência no CI