Planejamento de Etapas

# Etapa 4: Produção

Sócio Digital: Copiloto de Gestão Fiscal para Pequenos Negócios

## Objetivo

Colocar o sistema no ar de forma segura, observável e reproduzível, com decisões claras de hospedagem, conformidade com a LGPD e rotina de atualização do acervo.

## Ponto de partida

O Compose atual serve só ao ambiente local, com Ollama no host. O modelo de geração (Qwen3 8B) exige GPU para atender usuários reais. O CI faz lint e pytest. As normas mudam (por exemplo, a alíquota geral do ICMS-DF mudou em 2024), então o acervo precisa de atualização contínua.

## Resultado esperado

Ambientes de teste e produção com deploy automatizado, segurança, monitoramento e plano de atualização e recuperação.

## Resumo das issues

| ID | Issue | Prioridade | Responsável sugerido |
|---|---|---|---|
| E4.1 | Decidir a hospedagem do LLM e do embedding (ADR com custo) | Alta | Clara, Nasser e Ingrid |
| E4.2 | Containerização completa e Compose de produção | Alta | Ingrid |
| E4.3 | CI: build de imagens e testes de integração com Qdrant | Alta | Ingrid |
| E4.4 | CD: deploy automatizado em staging e produção | Alta | Ingrid |
| E4.5 | Segurança da API: limite de uso, segredos, CORS e cabeçalhos | Alta | Lucas e Ingrid |
| E4.6 | Conformidade com a LGPD | Alta | Clara e Nasser |
| E4.7 | Observabilidade: logs, métricas e alertas | Média | Ingrid |
| E4.8 | Feedback do usuário por resposta | Média | Lucas, com frontend a definir |
| E4.9 | Pipeline de atualização do acervo | Média | Lucas e Jhessica |
| E4.10 | Backup e restauração de Qdrant e PostgreSQL | Média | Ingrid |
| E4.11 | Teste de carga e dimensionamento | Média | Lucas e Ingrid |

Cada issue abaixo está escrita para ser copiada ao GitHub: o título da seção vira o título da issue; os rótulos indicados devem ser criados no repositório; a descrição e os critérios de aceite vão no corpo. Responsáveis e prioridades são sugestões e devem ser confirmados pela equipe.

# Issues

## [E4.1] Decidir a hospedagem do LLM e do embedding (ADR com custo)

**Responsável sugerido:** Clara, Nasser e Ingrid | **Prioridade:** Alta

**Rótulos:** etapa-4, decisão, infra | **Depende de:** Nenhuma

**Descrição**

Comparar servidor próprio com GPU, serviço gerenciado e API de LLM de terceiros quanto a custo mensal, latência, privacidade dos dados da empresa e esforço. É a decisão que mais impacta a arquitetura, e deve ser tomada cedo.

**Critérios de aceite**

- Quadro comparativo com custo estimado e latência medida
- Decisão registrada e aprovada pela equipe
- Impacto na API e na concorrência listado

---

## [E4.2] Containerização completa e Compose de produção

**Responsável sugerido:** Ingrid | **Prioridade:** Alta

**Rótulos:** etapa-4, infra, devops | **Depende de:** Decisão de hospedagem do LLM

**Descrição**

Imagens para API e frontend, serviços de Qdrant e PostgreSQL com volumes e backup, variáveis por ambiente e healthchecks. Remover a dependência de host.docker.internal para o modelo.

**Critérios de aceite**

- Todo o sistema sobe com um comando em ambiente limpo
- Configuração por variáveis, sem segredos no repositório
- Documentação de execução atualizada

---

## [E4.3] CI: build de imagens e testes de integração com Qdrant

**Responsável sugerido:** Ingrid | **Prioridade:** Alta

**Rótulos:** etapa-4, ci, devops | **Depende de:** Containerização completa

**Descrição**

Ampliar o CI com build das imagens, execução de testes de integração com Qdrant e Postgres em serviço e cache de dependências.

**Critérios de aceite**

- Imagens construídas a cada PR
- Testes de integração rodando no CI
- Tempo total do CI monitorado

---

## [E4.4] CD: deploy automatizado em staging e produção

**Responsável sugerido:** Ingrid | **Prioridade:** Alta

**Rótulos:** etapa-4, cd, devops | **Depende de:** CI de build de imagens

**Descrição**

Pipeline que publica imagens versionadas, implanta em staging a cada merge na main e em produção por aprovação, com forma de reverter.

**Critérios de aceite**

- Deploy em staging automático
- Produção com aprovação manual e reversão documentada
- Versão implantada visível na API

---

## [E4.5] Segurança da API: limite de uso, segredos, CORS e cabeçalhos

**Responsável sugerido:** Lucas e Ingrid | **Prioridade:** Alta

**Rótulos:** etapa-4, segurança, backend | **Depende de:** Autenticação

**Descrição**

Limitar requisições por usuário e por IP, gerenciar segredos fora do repositório, restringir CORS ao frontend, validar entradas e proteger contra abuso do endpoint de IA, que é caro de executar.

**Critérios de aceite**

- Limite de requisições com resposta 429
- Segredos em gerenciador, nunca no código
- Revisão de segurança (checklist) registrada

---

## [E4.6] Conformidade com a LGPD

**Responsável sugerido:** Clara e Nasser | **Prioridade:** Alta

**Rótulos:** etapa-4, lgpd, segurança | **Depende de:** Decisão de hospedagem do LLM

**Descrição**

CNPJ, faturamento e folha são dados da empresa e, em MEI, podem identificar uma pessoa. Definir base legal, política de privacidade, retenção, exclusão de conta e dados, e que dados chegam aos logs e a provedores externos de LLM.

**Critérios de aceite**

- Política de privacidade e termos redigidos
- Fluxo de exclusão de conta e dados implementado
- Logs sem dados sensíveis, verificado por teste
- Registro do que é enviado a serviços de terceiros

---

## [E4.7] Observabilidade: logs, métricas e alertas

**Responsável sugerido:** Ingrid | **Prioridade:** Média

**Rótulos:** etapa-4, observabilidade, devops | **Depende de:** Containerização completa

**Descrição**

Logs estruturados com identificador de requisição; métricas de latência por etapa (busca, geração), taxa de abstenção, erros e uso de GPU; alertas para indisponibilidade de Qdrant ou do modelo.

**Critérios de aceite**

- Painel com latência, erros e abstenção
- Alertas de indisponibilidade configurados
- Identificador de requisição ligando logs e resposta

---

## [E4.8] Feedback do usuário por resposta

**Responsável sugerido:** Lucas, com frontend a definir | **Prioridade:** Média

**Rótulos:** etapa-4, produto, backend | **Depende de:** Tela do Assistente fiscal; LGPD

**Descrição**

Permitir marcar uma resposta como útil ou incorreta, com comentário opcional, ligada à pergunta, às fontes e à versão do acervo e do modelo, para alimentar a revisão de qualidade.

**Critérios de aceite**

- Feedback persistido sem dados pessoais desnecessários
- Relatório periódico de respostas marcadas como incorretas

---

## [E4.9] Pipeline de atualização do acervo

**Responsável sugerido:** Lucas e Jhessica | **Prioridade:** Média

**Rótulos:** etapa-4, dados, devops | **Depende de:** Medição de qualidade no CI

**Descrição**

Rotina periódica para recoletar fontes, detectar normas alteradas, reprocessar o refino, reindexar no Qdrant e reavaliar a qualidade antes de promover a nova coleção. Manter a coleção anterior para voltar atrás.

**Critérios de aceite**

- Execução agendada e reproduzível
- Alterações detectadas com relatório
- Promoção só após a medição de qualidade passar
- Reversão para a coleção anterior documentada

---

## [E4.10] Backup e restauração de Qdrant e PostgreSQL

| | |
|---|---|
| **Responsável sugerido:** Ingrid | **Prioridade:** Média |
| **Rótulos:** etapa-4, infra, confiabilidade | **Depende de:** Containerização completa |

**Descrição**

Rotina de backup dos dados do usuário e da coleção, com teste de restauração. O README atual já alerta para não remover o volume do Qdrant.

**Critérios de aceite**

- Backups automáticos com retenção definida
- Restauração testada em ambiente separado

---

## [E4.11] Teste de carga e dimensionamento

| | |
|---|---|
| **Responsável sugerido:** Lucas e Ingrid | **Prioridade:** Média |
| **Rótulos:** etapa-4, desempenho, qualidade | **Depende de:** Consultas simultâneas; hospedagem definida |

**Descrição**

Simular usuários simultâneos no assistente para medir latência, taxa de erro e consumo, e definir o tamanho da infraestrutura e o número esperado de usuários no lançamento.

**Critérios de aceite**

- Cenários de carga versionados
- Limites medidos e registrados
- Meta de capacidade do lançamento definida

---