SÓCIO DIGITAL: COPILOTO DE GESTÃO FISCAL

Relatório Consolidado de Arquitetura, Inteligência de RAG Tributário e Práticas de DevOps/MLOps

Programa: Residência em Inteligência Artificial (RES-IA) | Desafio: Challenge 2 — Grupo 08
Integrantes: Clara, Ingrid, Jhessica, Lucas, Nasser | Data: Novembro / 2026

1. O Projeto Sócio Digital: Contexto e Fundamentos

O **Sócio Digital** é uma solução de Inteligência Artificial voltada para microempreendedores individuais (MEIs) e proprietários de microempresas (MEs e EPPs). No Brasil, pequenos negócios somam mais de **24 milhões de empresas ativas** (95% do total nacional). A complexidade normativa, a dispersão de portais públicos e a falta de formação contábil básica geram dependência cega do contador, ansiedade financeira e risco elevado de multas e desenquadramentos involuntários.

Essential Question (Pergunta Central da Equipe)

"Como a inteligência artificial generativa integrada a técnicas de recuperação factual (RAG) pode simplificar a gestão de obrigações contábeis e tributárias de pequenos empreendedores, promovendo maior autonomia e reduzindo a sobrecarga administrativa que afeta sua qualidade de vida?"

Diferencial Central da Solução

O diferencial do Sócio Digital é superar chatbots generalistas e conversas descartáveis: diante de uma dúvida relatada, o sistema extrai o contexto da empresa, consulta a base normativa por RAG, aciona o motor determinístico para cálculo exato e devolve um **plano de ação estruturado de no máximo 3 etapas concretas**, vinculando prazos, documentos e permitindo o acompanhamento do semáforo fiscal no painel do usuário.

Fronteiras Éticas e Delimitação Legal

O assistente opera como copiloto educativo e organizador. **Não substitui as atribuições privativas de contadores habilitados (CRC)** nem comprova regularidade perante o Fisco sem consulta oficial. O sistema incorpora abstenção ativa em matérias de incerteza ou litígio, encaminhando formalmente o usuário para validação especializada com seu contador.

Matriz de Requisitos Centrais do Sistema (MVP)

ID	Requisito Funcional / Não Funcional	Descrição Técnica & Critério no MVP	Prioridade
RF01	Cadastro do Contexto	Registro de porte (MEI/ME), CNAE, regime tributário e localização.	Alta
RF02/03	Assistente & RAG Factual	Interface conversacional com recuperação estrita de fontes consolidadas (LC 123, CGSN).	Alta
RF06/07	Painel & Planos de Ação	Dashboard com semáforo de status e geração de roteiros de ação em até 3 etapas.	Alta
RNF04	Tratamento de Incertezas	Abstenção proativa e encaminhamento ao CRC se a base normativa for insuficiente.	Crítica
RNF05	Citações Verificáveis	Citação explícita do artigo, parágrafo e data de vigência da lei em toda orientação.	Alta
RNF08	Latência Controlada	Tempo de resposta inferior a 3s no motor determinístico e < 10s no pipeline RAG.	Média

2. Inteligência e Arquitetura do RAG Tributário (Ciência de Dados)

A frente de Ciência de Dados (liderada por Jhessica) estruturou uma arquitetura especializada de RAG para solucionar a complexidade jurídica brasileira. O 'chunking ingênuo' por quantidade cega de caracteres quebra a hierarquia legal (artigos, parágrafos e incisos), separando regras gerais de suas condições de exceção. Para garantir zero alucinações normativas, o sistema fundamenta-se em quatro pilares:

Os Quatro Pilares da Solução de RAG

1. **Chunking Hierárquico Jurídico (LegalHierarchicalChunker):** Parser ciente da estrutura normativa brasileira (`ARTICLE_REGEX`, `PARAGRAPH_REGEX`). Preserva a integridade do Artigo e seus Parágrafos. Aplica **Context Injection** gerando cabeçalhos como [FONTE: LC 123 | ARTIGO: Art. 18 | PARÁGRAFO: § 5º-J | TEMA: Fator R] antes do embedding. Em artigos extensos, subdivide em parágrafos preservando o *Caput* como âncora fixa.
2. **Banco Vetorial e Busca Híbrida (LegalVectorStore):** Indexação semântica densa com sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2 (384 dimensões) com fallback em TF-IDF/Python puro. Persistência em SQLite com vetores serializados. A recuperação calcula o score: **0.70 × Similaridade Cosseno + 0.30 × Correspondência Léxica Exata**, com filtros temáticos particionados por tags fiscais (`mei`, `fator_r`, `desenquadramento`, etc.).
3. **Extrator de Entidades Fiscais e NER (TaxEntityExtractor):** Identificação em milissegundos de CNPJs, CNAEs, regimes, anexos e valores monetários (distinguindo faturamento anual RBT12, faturamento mensal, folha 12m e débitos tributários). Aplica **Query Expansion**, traduzindo perguntas em linguagem coloquial para a terminologia oficial.
4. **Desacoplamento Determinístico vs Generativo (Garantia Antialucinação):** Separação arquitetural estrita (Clara e Nasser): **o LLM nunca realiza cálculos matemáticos de impostos**. O extrator fornece dados para o motor em Python (FiscalCalculator do Lucas), que calcula a alíquota efetiva (Art. 18 da LC 123/2006) e Fator R. O RAG recupera a lei. O LLM apenas redige a explicação.

Corpora Oficiais Ingeridos e Indexados no Banco Vetorial

Documento Fonte	Esfera & Órgão	Conteúdo Normativo Mapeado	Escopo Indexado
Lei Complementar nº 123/2006	Presidência da República	Estatuto da MPE, Anexos I a V, Fator R, sublimites e MEI.	Artigos 18, 18-A e §§
Resolução CGSN nº 140/2018	Comitê Gestor Simples	Regulamento operacional, declarações (DASN-SIMEI) e multas.	Artigos 106 e segs.
Manual de Regularização Fiscal	Receita Federal / PGFN	Emissão de certidões (CND/CPEN), parcelamentos e cobrança.	Artigos 1º a 15
Catálogo Oficial de CNAEs & Anexos	IBGE / Comitê Simples	Tabelas completas de alíquotas nominais e Fator R por CNAE.	JSON estruturado / FTS5

Validação Empírica dos Casos Canônicos de Teste (100% de Sucesso)

Cenário de Teste	Pergunta do Usuário	Artigo Legal Recuperado (Top-1)	Status
1. Limite e Excesso MEI	Faturei R$ 105 mil no MEI (> 20% de excesso). Serei desenquadrado?	LC 123/2006, Art. 18-A, § 7º (Desenquadramento retroativo a 1º jan)	**100% OK**
2. Fator R e Anexos	CNAE 6201-5/01 faturou R$ 300k com folha de R$ 90k (30%). Qual anexo?	LC 123/2006, Art. 18, §§ 5º-J e 5º-M (Fator R >= 28% -> Anexo III)	**100% OK**
3. Obrigação Acessória	Qual a data limite da DASN-SIMEI e valor da multa por atraso?	Res. CGSN 140/2018, Art. 106 (Prazo 31 de maio e multa mín. R$ 50)	**100% OK**
4. Regularização e CPEN	Recebi notificação de dívida de R$ 15 mil. O parcelamento em 60x libera CPEN?	Manual Receita Federal, Art. 1º (Parcelamento ativo emite certidão positiva)	**100% OK**

3. Práticas de DevOps e MLOps: Esteira e Governança

A frente de Ops (liderada por Ingrid) estabeleceu a infraestrutura automatizada de Integração Contínua (CI), governança de dados normativos e esteiras reproduzíveis via containers, garantindo rastreabilidade total entre versões de código, modelos de RAG e tabelas fiscais.

Stack Tecnológica Integrada de DevOps e MLOps

Componente	Tecnologia Adotada	Propósito e Escopo de Operação
Controle de Versão	Git & GitHub	Repositório central `ingrdsoares/RES-IA-Challenge-2` com fluxo estrito de PRs.
Portal Docs-as-Code	Docsify / Pages	Documentação viva renderizada via CDN e deployada pelo GitHub Actions (`pages.yml`).
Integração Contínua (CI)	GitHub Actions	Pipeline multi-job (`ci.yml`) disparada a cada push/PR para linters, testes e builds.
Versionamento de Dados	DVC (Data Version Control)	Rastreamento de corpora fiscais e bancos SQLite com integridade por SHA-256.
Padronização de Código	Ruff & Pytest	Linter e formatador de alta performance configurados no `pyproject.toml`.
Conteinerização	Docker (FastAPI)	Imagem leve e segura (`python:3.12-slim`) em `api/Dockerfile` para os microsserviços.

Esteira de Integração Contínua (Workflow GitHub Actions)

A esteira automatizada em .github/workflows/ci.yml opera como o primeiro portão de qualidade do projeto. A cada alteração enviada ao repositório, quatro validações críticas são executadas em paralelo:

- **Job `lint` (Qualidade de Código):** Checagem de tipagem e formatação via Ruff em menos de 2 segundos.
- **Job `test` (Testes Unitários e Fiscais):** Executa o Pytest para validar as rotas da API e os motores de cálculo.
- **Job `dvc-validation` (Integridade de Dados):** Executa `dvc doctor` e checa se há drift de ponteiros normativos.
- **Job `docker-smoke-test` (Build de Imagem):** Executa o build da imagem Docker da API para garantir deployabilidade.

Governança e Versionamento de Dados com DVC

Seguindo a política de segregação de artefatos volumosos, o DVC separa o ciclo de vida do código das bases tributárias: **`data/raw/`** guarda arquivos brutos auditáveis e imutáveis, enquanto **`data/processed/`** recebe o banco relacional e os índices vetoriais. Cada versão de dados gera um arquivo ponte de metadados (`.dvc`) com hash SHA-256, permitindo que qualquer membro da equipe sincronize exatamente a mesma base legal com dvc pull.

> **Diretriz de MLOps: Rastreabilidade Estrita de Dados**
>
> **Padrão de Governança de Corpora Fiscais (DVC):**
> • Arquivos de dados binários (*.db) e índices vetoriais não são comitados diretamente no Git.
> • Cada atualização em tabelas do Simples ou manuais fiscais gera um commit no Git contendo apenas os ponteiros `.dvc`.
> • Armazenamento configurado com suporte a remotes locais compartilhados e compatibilidade nativa com buckets S3/GCP.

4. Governança da Equipe e Roadmap de Entrega

O projeto organiza-se em um modelo colaborativo multidisciplinar com responsabilidades claramente distribuídas entre Engenharia de Dados, Ciência de Dados, Arquitetura de Software e DevOps/MLOps:

Matriz de Atribuições da Equipe (Grupo 08)

Integrante	Frente de Atuação	Entregas Concluídas	Próximos Passos Imediatos
Lucas	Engenharia de Dados & Dev	Motor fiscal (`calculator.py`), base CNAEs e tabelas LC 123.	Conectar endpoints da API FastAPI ao motor fiscal.
Jhessica	Ciência de Dados	Chunking hierárquico, VectorStore SQLite e NER Fiscal.	Engenharia de prompt final e métricas Ragas.
Clara e Nasser	Arquitetura de Soluções	Topologia desacoplada, segurança/LGPD e fronteira CRC.	Contratos de OpenAPI e modelo multi-tenant.
Ingrid	Ops (DevOps & MLOps)	GitHub Actions (CI/Pages), DVC e governança de repositório.	Merge da branch de RAG e deploy contínuo (CD).

Critérios de Avaliação e Indicadores de Sucesso (Go/No-Go)

A passagem para a fase de inferência em produção obedece a métricas objetivas de qualidade:

- **Acurácia e Corretude Normativa:** Meta de **pelo menos 85% de exatidão global e 0% de erros críticos** em cenários de enquadramento tributário auditados por especialistas contábeis.
- **Ancoragem Legal (Faithfulness):** Meta de **pelo menos 95% das orientações com citações legais diretas** e verificáveis nos diplomas da LC 123/2006 ou Resoluções do CGSN.
- **Compreensão Prática:** Pelo menos 80% dos usuários capazes de executar o plano de 3 passos sem dúvidas adicionais.
- **Desempenho de Latência:** Inferência na API em menos de 3 segundos para cálculos matemáticos e menos de 10 segundos para respostas completas ancoradas em RAG.

Checklist de Execução para a Próxima Entrega Oficial

Roteiro de Fechamento da Fase 2 e Transição para a Fase 3:

1. **Merge Oficial da Branch RAG:** Realizar a integração de `origin/feat/rag-pipeline-ingestao` na branch `main`.
2. **Rastreamento Efetivo DVC:** Executar `dvc add data/raw` e registrar os arquivos de manifesto SHA-256 no Git.
3. **Exposição dos Endpoints da API:** Implementar rotas `/api/v1/consultar-duvida` e `/api/v1/simular-simples`.
4. **Pipeline de Validação Contínua de RAG:** Integrar os testes de recuperação factual ao CI do GitHub Actions.
5. **Ambiente de Homologação:** Configurar deploy automático da API conteinerizada em ambiente de nuvem.